



TRABALHO DE SISTEMAS INTELIGENTES

RELATÓRIO DA TAREFA 1

Andre Luis Raksa Vieira

CURITIBA
SETEMBRO
2025



SUMÁRIO

1. DATASETS UTILIZADOS	2
2. CLASSIFICADOR CART	2
2.1. PARAMETRIZAÇÕES	2
2.2. RESULTADOS DO TREINO	3
2.3. TABELA DE F-SCORES MÉDIOS	3
2.4. TABELA DE VARIÂNCIAS	3
2.5. ESCOLHA DA MELHOR PARAMETRIZAÇÃO	4
2.6. ESCOLHA DO MELHOR MODELO	4
2.7. RESULTADOS DO TESTE CEGO	4
2.8. RESULTADOS E DISCUSSÃO	5
3. REGRESSOR DE REDE NEURAL MLP	6
3.1. PARAMETRIZAÇÕES	6
3.2. RESULTADOS DO TREINO	6
3.3. TABELA DE MSE MÉDIOS	7
3.4. TABELA DE VARIÂNCIAS	7
3.5. ESCOLHA DA MELHOR PARAMETRIZAÇÃO	7
3.6. ESCOLHA DO MELHOR MODELO	8
3.7. RESULTADOS DO TESTE CEGO	8
3.8. RESULTADOS E DISCUSSÃO	8



1. DATASETS UTILIZADOS

Para o treinamento dos modelos foi utilizado somente um Dataset, nomeado de “*data_gerada*”, gerado com os seguintes parâmetros:

- Número de Vítimas: 2000
- Idade Média: 40
- Desvio de Idade: 3
- Tipo de Acidente: Uniforme
- Nível de Ruído: 0.2

A separação entre dados de treino e teste foi de 0.2, com 80% dos dados (1600) sendo destinados a treinamento, e os 20% restantes (400) para teste/validação. Foi realizado validação cruzada com os dados de treino usando 3 folds para cada uma das parametrizações. Posteriormente o melhor modelo escolhido foi utilizado para predição do Dataset disponibilizado pelo professor, renomeado de “*data_gabarito*”.

2. CLASSIFICADOR CART

Para o classificador, foi escolhido um modelo de classificação por árvore de decisão CART, desenvolvido em python usando a biblioteca scikit-learn.

2.1. PARAMETRIZAÇÕES

As três parametrizações do classificador foram obtidas do método *GridSearchCV* sobre os conjuntos $\text{max_depth} = \{8\}$ e $\text{min_samples_leaf} = \{64, 256, 512\}$, resultando em:

- Parametrização 1: **criterion** = entropy, **max_depth** = 8, **min_samples_leaf** = 64
- Parametrização 2: **criterion** = entropy, **max_depth** = 8, **min_samples_leaf** = 256
- Parametrização 3: **criterion** = entropy, **max_depth** = 8, **min_samples_leaf** = 512.



2.2. RESULTADOS DO TREINO

Parametrização 1

f-score	fold 1	fold 2	fold 3	Média	Variância
Treino	0.825	0.808	0.816	0.816	0.000046
Validação	0.799	0.833	0.817	0.816	0.000186

Parametrização 2

f-score	fold 1	fold 2	fold 3	Média	Variância
Treino	0.732	0.808	0.816	0.785	0.001435
Validação	0.717	0.833	0.817	0.789	0.002628

Parametrização 3

f-score	fold 1	fold 2	fold 3	Média	Variância
Treino	0.307	0.304	0.304	0.305	0.000003
Validação	0.300	0.307	0.308	0.305	0.000012

2.3. TABELA DE F-SCORES MÉDIOS

f-score Médio	Param 1	Param 2	Param 3
Treino	0.816	0.785	0.305
Validação	0.816	0.789	0.305

2.4. TABELA DE VARIÂNCIAS

Variância	Param 1	Param 2	Param 3
Treino	0.000046	0.001435	0.000003
Validação	0.000186	0.002628	0.000012



2.5. ESCOLHA DA MELHOR PARAMETRIZAÇÃO

A melhor parametrização escolhida foi a 1. Para a escolha da melhor parametrização, buscava-se aquela com o menor erro estimado, sendo *erro estimado* = *variância* + *viés*. A variância e o viés eram calculados utilizando os f-scores de todos os folds de uma determinada parametrização.

Além disso, o f-score de validação médio entre folds deveria ser maior do que 0.75, com o objetivo de evitar modelos subajustados. No caso de nenhuma das parametrizações ter o valor maior do que 0.75, era simplesmente escolhida a com maior f-score de validação médio.


2.6. ESCOLHA DO MELHOR MODELO

O método *GridSearchCV* não permite diretamente acessar os modelos temporários criados em cada fold de uma dada parametrização, portanto, a escolha do melhor modelo para o classificador CART foi aquele gerado pelo treinamento com todos os dados de treino, e utilizando a melhor parametrização escolhida.

2.7. RESULTADOS DO TESTE CEGO

Ao utilizar o melhor modelo para predizer o dataset de teste cego “*data_gabarito*” obteve-se os seguintes resultados e matriz de confusão:

- Precisão: 92.60%
- F-score: 0.926011
- Recall: 0.925648



Matriz de Confusão do Teste Cego.

2.8. RESULTADOS E DISCUSSÃO

Com base nos resultados apresentados, é possível afirmar que o modelo escolhido apresenta boa capacidade de generalização. A acurácia nos dados separados para treino obtida pelo modelo foi de 81.69%, enquanto que de teste foi de 80.00%. As duas faixas estão próximas, indicando que o modelo não sofreu com sobreajuste. Além disso, a acurácia do modelo retreinado com o conjunto completo, permanece dentro da mesma faixa, em 81.35%.

Os resultados obtidos no teste cego, mostram uma melhora expressiva no desempenho do modelo, em termos de precisão, f-score e recall. Portanto, considerando a baixa diferença entre treino e teste, a estabilidade após o retreinamento, e o excelente desempenho no teste cego, conclui-se que o modelo selecionado possui uma capacidade de generalização satisfatória.



3. REGRESSOR DE REDE NEURAL MLP

Para o regressor foi escolhido um modelo de regressão por rede neural MLP, desenvolvido em python usando a biblioteca scikit-learn

3.1. PARAMETRIZAÇÕES

As três parametrizações do regressor foram obtidas alterando-se a configuração de camadas “*hidden_layer_sizes*” (neurônios por camada e quantidade de camadas), e a taxa de aprendizado inicial “*learning_rate_init*”, resultando nas seguintes:

- Parametrização 1: ***hidden_layer_sizes*** = (4, 4), ***activation*** = tanh, ***solver*** = sgd, ***learning_rate*** = adaptive, ***learning_rate_init*** = 0.01, ***max_iter*** = 10000, ***shuffle*** = True, ***momentum*** = 0.95
- Parametrização 2: ***hidden_layer_sizes*** = (10, 10, 10, 10, 10, 10), ***activation*** = tanh, ***solver*** = sgd, ***learning_rate*** = adaptive, ***learning_rate_init*** = 0.025, ***max_iter*** = 10000, ***shuffle*** = True, ***momentum*** = 0.95
- Parametrização 3: ***hidden_layer_sizes*** = (20, 20, 20, 20, 20, 20, 20, 20, 20, 20, 20, 20, 20, 20, 20), ***activation*** = tanh, ***solver*** = sgd, ***learning_rate*** = adaptive, ***learning_rate_init*** = 0.03, ***max_iter*** = 10000, ***shuffle*** = True, ***momentum*** = 0.95

3.2. RESULTADOS DO TREINO

Parametrização 1

MSE NEG	fold 1	fold 2	fold 3	Média	Variância
Treino	-0.031386	-0.052103	-0.030141	-0.037877	0.000101
Validação	-0.040060	-0.046420	-0.030773	-0.039084	0.000041



Parametrização 2

MSE NEG	fold 1	fold 2	fold 3	Média	Variância
Treino	-0.029279	-0.032702	-0.032661	-0.031547	0.000003
Validação	-0.035540	-0.029646	-0.030721	-0.031969	0.000007

Parametrização 3

MSE NEG	fold 1	fold 2	fold 3	Média	Variância
Treino	-0.024549	-0.027728	-0.027466	-0.026581	0.000002
Validação	-0.033069	-0.028125	-0.026391	-0.029195	0.000008

3.3. TABELA DE MSE MÉDIOS

MSE NEG Médio	Param 1	Param 2	Param 3
Treino	-0.037877	-0.031547	-0.026581
Validação	-0.039084	-0.031969	-0.029195

3.4. TABELA DE VARIÂNCIAS

Variância	Param 1	Param 2	Param 3
Treino	0.000101	0.000003	0.000002
Validação	0.000041	0.000007	0.000008

3.5. ESCOLHA DA MELHOR PARAMETRIZAÇÃO

A melhor parametrização escolhida foi a 3. Similar ao classificador, para a escolha da melhor parametrização, buscava-se aquela com o menor erro estimado, sendo *erro estimado* = *variância* + *viés*. A variância e o viés eram calculados utilizando os MSEs negativos de todos os folds de uma determinada parametrização.



Além disso, o MSE negativo de validação médio entre folds deveria ser maior do que -0.5, com o objetivo de evitar modelos subajustados. No caso de nenhuma das parametrizações ter o valor maior do que -0.5, era simplesmente escolhida a com maior MSE negativo de validação médio.

3.6. ESCOLHA DO MELHOR MODELO

O melhor modelo escolhido foi o do fold 3. Visto que, dada a seleção da melhor parametrização, a escolha do melhor modelo para o regressor RN MLP, é simplesmente aquele com o maior MSE negativo de validação entre os folds (o mais próximo de zero).

3.7. RESULTADOS DO TESTE CEGO

Ao utilizar o melhor modelo para predizer o dataset de teste cego "*data_gabarito*" obteve-se um MSE negativo de -0.0155.

3.8. RESULTADOS E DISCUSSÃO

Com base nos resultados apresentados, é possível afirmar que o modelo escolhido apresenta boa capacidade de generalização. Nos dados separados para treino, o MSE obtido pelo modelo foi de -0.0271, enquanto que de teste foi de -0.0315. Os dois valores estão próximos, indicando que o modelo não sofreu com sobreajuste. Além disso, o MSE do modelo retreinado com o conjunto completo, permanece próximo em, -0.0258.

De forma similar ao classificador, os resultados obtidos no teste cego, mostram uma melhora considerável no desempenho do modelo, em termos de MSE negativo. Portanto, considerando a baixa diferença entre treino e teste, a estabilidade após o retreinamento, e o excelente desempenho no teste cego, conclui-se que o modelo regressor selecionado, também possui uma capacidade de generalização satisfatória.